

计算图、反向传播与梯度下降：深度学习核心数学基础

Anson, 深度学习社 Cooperated with Kimi K2 0905

2025 年 10 月 17 日

摘要

本文深入探讨了深度学习中的三个核心数学基础：计算图表示、反向传播算法和梯度下降优化。通过 MNIST 手写数字识别任务作为贯穿始终的实例，我们从基础概念出发，结合详细的数学推导、直观的图示和完整的 PyTorch 实现，系统性地阐述了这些技术在深度学习中的重要作用。文章首先介绍计算图如何将复杂的数学表达式可视化为图结构，然后详细推导反向传播算法如何基于链式法则高效计算梯度，最后探讨梯度下降如何利用梯度信息优化模型参数。通过实际的代码示例，我们展示了现代深度学习框架中的自动微分系统实现，并提供了实用的优化策略和实际应用指导。本文不仅涵盖基本理论，还包含了可运行的 Python 代码，帮助读者深入理解这些核心概念的实际应用。

目录

1	引言	4
1.1	学习目标与核心概念	4
1.2	机器学习的基本问题	4
1.3	为什么需要计算图、反向传播和梯度下降?	4
2	计算图基础	5
2.1	什么是计算图?	5
2.2	计算图的基本元素	6
2.2.1	节点类型	6
2.2.2	边的语义	6
2.3	计算图的构建规则	7
2.4	复杂模型的表示	7

3	前向传播	7
3.1	前向传播的基本概念	7
3.2	拓扑排序的重要性	8
3.3	前向传播的详细步骤	8
3.4	前向传播的计算复杂度	9
4	反向传播	9
4.1	为什么需要反向传播?	9
4.2	链式法则：反向传播的数学基础	9
4.3	反向传播的直观理解	10
4.4	反向传播的直观理解	10
4.5	反向传播的算法步骤	11
4.6	详细计算示例	11
4.7	计算图可视化：前向传播与反向传播对比	12
4.8	常见操作的梯度计算规则	12
5	梯度下降	13
5.1	优化问题的数学表述	13
5.2	梯度下降的基本思想	13
5.3	梯度下降的数学表达	14
5.4	学习率的重要性	14
5.5	梯度下降的变体	14
5.6	梯度下降的收敛性分析	15
6	综合实例：训练线性回归模型	15
6.1	问题设定	15
6.2	计算图表示	16
6.3	详细训练过程	16
6.4	多轮迭代的收敛过程	16
7	现代深度学习框架的实现	17
7.1	自动微分系统	17
7.2	PyTorch 实现：手动构建计算图	17
7.3	现代优化器的工作机制与对比	19
7.3.1	优化器的基本框架	19
7.3.2	随机梯度下降 (SGD)	19
7.3.3	带动量的 SGD (SGD+Momentum)	20
7.3.4	RMSprop 优化器	21

7.3.5 Adam 优化器	22
7.3.6 优化器对比分析	24
7.3.7 优化器选择指导	24
7.4 优化器的抽象	24
7.5 梯度消失与梯度爆炸	25
7.6 二阶优化方法	25
7.7 自适应优化算法	26
8 结论与实践指导	26
8.1 核心概念总结与学习成果	26
8.2 实践应用指南	28
8.3 从理论到实践的进阶路径	29

1 引言

1.1 学习目标与核心概念

在深入探讨计算图、反向传播和梯度下降之前，让我们明确本章节的学习目标：

学习目标

- **理解计算图**：掌握如何将复杂的数学表达式表示为图结构
- **掌握反向传播**：理解基于链式法则的梯度计算机制
- **应用梯度下降**：学会使用梯度信息优化模型参数
- **实践自动微分**：能够在 PyTorch 中实现和调试这些概念
- **解决实际问题**：通过 MNIST 实例理解这些技术的实际应用

1.2 机器学习的基本问题

机器学习的目标是让计算机从数据中学习模式，而不需要明确编程每一个规则。这种学习过程的核心在于如何自动调整模型的参数，使其能够更好地拟合数据并做出准确的预测。

机器学习的核心挑战

- **模型复杂度**：现代机器学习模型（特别是深度神经网络）包含数百万甚至数十亿个参数
- **优化难度**：在高维参数空间中寻找最优解是一个极具挑战性的问题
- **计算效率**：需要高效的算法来处理大规模数据和复杂模型
- **泛化能力**：确保模型在未见过的数据上表现良好

1.3 为什么需要计算图、反向传播和梯度下降？

这三个概念构成了现代深度学习的基础设施：

1. **计算图**：将复杂的数学表达式可视化为图结构，便于理解和计算
2. **反向传播**：高效计算梯度（偏导数）的算法，告诉我们每个参数对最终输出的影响程度

3. 梯度下降：利用梯度信息优化参数的迭代算法，逐步减小损失函数

历史背景

这些概念的发展历程可以追溯到 20 世纪 60-80 年代：

- 1960s：链式法则在神经网络中的应用首次被提出
- 1970s：反向传播算法的雏形出现
- 1986 年：Rumelhart、Hinton 和 Williams 重新发现并推广了反向传播算法
- 1990s 至今：这些技术成为所有深度学习框架的核心

2 计算图基础

2.1 什么是计算图？

计算图（Computational Graph）是一种将数学表达式表示为有向图的数据结构。图中的节点代表变量或操作，边代表数据流动的方向。这种表示方法不仅直观，而且为自动微分提供了数学基础。

计算图的正式定义

计算图 $G = (V, E)$ 是一个有向图，其中：

- V 是节点集合，包括：
 - 输入节点：表示变量或常数
 - 操作节点：表示数学运算（加法、乘法、函数等）
 - 输出节点：表示最终计算结果
- E 是边集合，表示数据依赖关系
- 每个节点 $v \in V$ 都有一个对应的值 $val(v)$
- 边 $(u, v) \in E$ 表示节点 u 的值是节点 v 的输入

2.2 计算图的基本元素




图 1: 计算图示例: $f(x, y) = (x + y) \times y$

2.2.1 节点类型

输入节点 (Input Nodes)

- 表示模型的输入变量或常数
- 通常是计算图的起点
- 在训练过程中，这些节点的值会被赋予具体数值
- 示例: x, y, w, b 等

操作节点 (Operation Nodes)

- 表示数学运算或函数
- 接收一个或多个输入，产生一个输出
- 示例: 加法 (+)、乘法 (\times)、 $\text{sigmoid}(\sigma)$ 、ReLU 等
- 每个操作节点都对应一个前向计算和反向传播规则

2.2.2 边的语义

边在计算图中承载着重要的语义信息:

- **数据流**: 表示数值从源节点流向目标节点
- **依赖关系**: 显示计算过程中的依赖关系
- **梯度传播**: 在反向传播中，梯度沿着边反向流动
- **计算顺序**: 边的方向决定了计算的拓扑顺序

2.3 计算图的构建规则

构建计算图需要遵循特定的规则，以确保计算的正确性和效率：

构建原则

1. **无环性**：计算图必须是有向无环图（DAG），避免循环依赖
2. **完整性**：每个操作节点的所有输入都必须有明确的来源
3. **一致性**：数据类型和维度必须匹配
4. **可微分性**：所有操作节点必须支持前向计算和反向传播

2.4 复杂模型的表示

现代深度学习模型可以表示为极其复杂的计算图。以逻辑回归为例：




图 2: 逻辑回归模型的计算图表示: $\hat{y} = \sigma(w_1x_1 + w_2x_2 + b)$

这个计算图清晰地展示了逻辑回归模型的完整计算过程：

- 输入特征 x_1, x_2 与权重 w_1, w_2 相乘
- 加权和加上偏置项 b
- 通过 sigmoid 函数 σ 得到概率预测 \hat{y}

3 前向传播

3.1 前向传播的基本概念

前向传播（Forward Propagation）是指沿着计算图从输入节点到输出节点的计算过程。在这个过程中，每个节点的值都基于其输入节点的值计算得出。

前向传播的数学定义

对于计算图 $G = (V, E)$ ，前向传播算法可以形式化描述为：

1. 对每个输入节点 $v \in V_{input}$ ，设置 $val(v)$ 为给定的输入值
2. 按照拓扑顺序遍历所有节点 $v \in V$
3. 对于每个操作节点 v ，计算：

$$val(v) = f_v(val(u_1), val(u_2), \dots, val(u_k))$$

其中 u_1, u_2, \dots, u_k 是 v 的所有前驱节点， f_v 是节点 v 对应的操作函数

3.2 拓扑排序的重要性

拓扑排序确保在计算一个节点的值之前，其所有输入节点的值都已经计算完毕。这是前向传播正确性的关键保证。

拓扑排序示例

考虑计算图： $c = a + b, e = c \times d$

- 有效拓扑顺序： $[a, b, d, c, e]$ 或 $[b, a, d, c, e]$
- 无效顺序： $[c, a, b, d, e]$ （计算 c 时 a 和 b 还未计算）

3.3 前向传播的详细步骤


让我们通过具体例子详细分析前向传播的过程：

详细计算

假设 $x = 3, y = 2$ ：

计算步骤：

1. 初始化输入节点： $x = 3, y = 2$
2. 计算 $u = x + y = 3 + 2 = 5$
3. 计算 $f = u \times y = 5 \times 2 = 10$
4. 得到最终结果： $f(3, 2) = 10$



3.4 前向传播的计算复杂度

前向传播的计算复杂度取决于计算图的结构和操作类型：

操作类型	时间复杂度	空间复杂度
基本算术运算	$O(1)$	$O(1)$
矩阵乘法	$O(n^3)$	$O(n^2)$
卷积操作	$O(k \cdot n^2)$	$O(n^2)$
激活函数	$O(n)$	$O(n)$

表 1: 常见操作的计算复杂度

其中 n 表示输入尺寸， k 表示卷积核大小。

4 反向传播

4.1 为什么需要反向传播？

在机器学习中，我们不仅需要计算模型的输出，更重要的是要知道如何调整参数来改进模型性能。反向传播（Backpropagation）算法解决了这个核心问题。

梯度计算的重要性

- **参数优化：** 梯度告诉我们每个参数应该向哪个方向调整
- **影响分析：** 了解每个参数对最终输出的贡献程度
- **训练效率：** 高效的梯度计算大大加速了模型训练
- **理论保证：** 为各种优化算法提供数学基础

4.2 链式法则：反向传播的数学基础

链式法则是多元微积分中的基本定理，也是反向传播算法的核心：

链式法则 (Chain Rule)

如果 $z = f(y)$ 且 $y = g(x)$, 那么:

$$\frac{dz}{dx} = \frac{dz}{dy} \times \frac{dy}{dx}$$

对于多元函数, 如果 $z = f(y_1, y_2, \dots, y_n)$ 且每个 $y_i = g_i(x)$, 那么:

$$\frac{\partial z}{\partial x} = \sum_{i=1}^n \frac{\partial z}{\partial y_i} \times \frac{\partial y_i}{\partial x}$$

4.3 反向传播的直观理解

反向传播可以理解为” 责任分配” 的过程:

责任分配类比

想象一个公司组织:

- **前向传播**: 信息从基层员工流向总经理
- **反向传播**: 当公司业绩不佳时, 责任从总经理反向分配到各个部门和个人
- **梯度**: 每个部门或个人对最终结果的” 责任程度”
- **参数更新**: 根据责任程度调整工作方式

4.4 反向传播的直观理解

反向传播可以理解为” 责任分配” 的过程:

责任分配类比

想象一个公司组织:

- **前向传播**: 信息从基层员工流向总经理
- **反向传播**: 当公司业绩不佳时, 责任从总经理反向分配到各个部门和个人
- **梯度**: 每个部门或个人对最终结果的” 责任程度”
- **参数更新**: 根据责任程度调整工作方式

4.5 反向传播的算法步骤

反向传播算法可以形式化地描述为以下步骤：

反向传播算法

1. **前向传播**：计算所有节点的值并保存中间结果
2. **初始化梯度**：设置输出节点的梯度为 $\frac{\partial L}{\partial L} = 1$
3. **反向遍历**：按照逆拓扑顺序遍历所有节点
4. **梯度计算**：对于每个节点 v ，计算其对损失函数的梯度：

$$\frac{\partial L}{\partial v} = \sum_{u \in \text{后继}(v)} \frac{\partial L}{\partial u} \times \frac{\partial u}{\partial v}$$

5. **参数梯度**：对于参数节点，计算 $\frac{\partial L}{\partial \theta}$ 用于后续优化

4.6 详细计算示例

让我们通过具体例子详细分析反向传播的过程：

反向传播计算

假设 $x = 3, y = 2$ ，我们要计算 $\frac{\partial f}{\partial x}$ 和 $\frac{\partial f}{\partial y}$ ：

前向传播结果：

- $u = x + y = 3 + 2 = 5$
- $f = u \times y = 5 \times 2 = 10$

反向传播计算：

1. 初始化： $\frac{\partial f}{\partial f} = 1$
2. 计算 $\frac{\partial f}{\partial u} = \frac{\partial}{\partial u}(u \times y) = y = 2$
3. 计算 $\frac{\partial f}{\partial y} = \frac{\partial}{\partial y}(u \times y) + \frac{\partial f}{\partial u} \times \frac{\partial u}{\partial y} = u + 2 \times 1 = 5 + 2 = 7$
4. 计算 $\frac{\partial f}{\partial x} = \frac{\partial f}{\partial u} \times \frac{\partial u}{\partial x} = 2 \times 1 = 2$

结果： $\frac{\partial f}{\partial x} = 2, \frac{\partial f}{\partial y} = 7$

4.7 计算图可视化：前向传播与反向传播对比

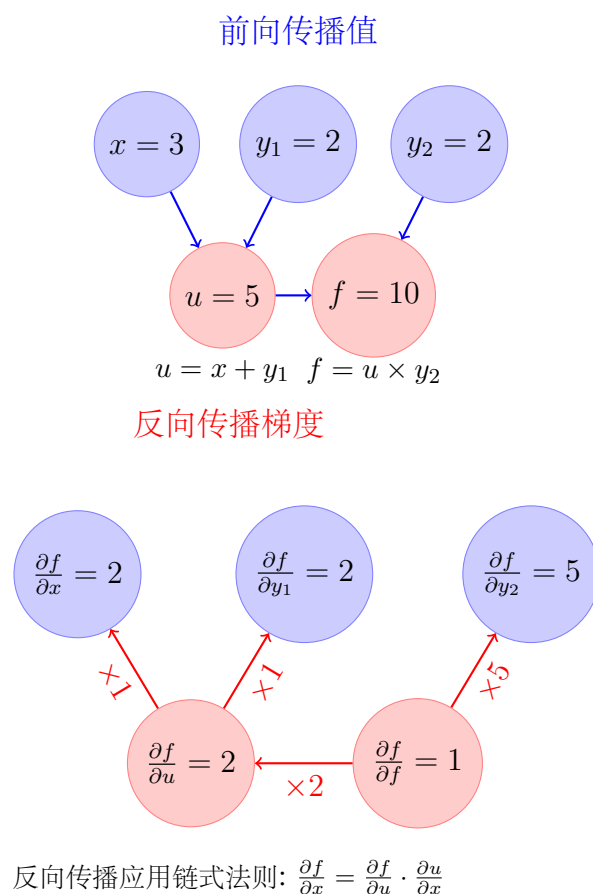


图 3: 前向传播与反向传播对比示意图

4.8 常见操作的梯度计算规则

在反向传播中，我们需要为每种操作定义梯度计算规则：

操作类型	前向计算	反向梯度
加法	$z = x + y$	$\frac{\partial L}{\partial x} = \frac{\partial L}{\partial z}, \frac{\partial L}{\partial y} = \frac{\partial L}{\partial z}$
乘法	$z = x \times y$	$\frac{\partial L}{\partial x} = \frac{\partial L}{\partial z} \times y, \frac{\partial L}{\partial y} = \frac{\partial L}{\partial z} \times x$
矩阵乘法	$Z = X \cdot Y$	$\frac{\partial L}{\partial X} = \frac{\partial L}{\partial Z} \cdot Y^T, \frac{\partial L}{\partial Y} = X^T \cdot \frac{\partial L}{\partial Z}$
ReLU	$z = \max(0, x)$	$\frac{\partial L}{\partial x} = \begin{cases} \frac{\partial L}{\partial z} & \text{if } x > 0 \\ 0 & \text{otherwise} \end{cases}$
Sigmoid	$z = \sigma(x)$	$\frac{\partial L}{\partial x} = \frac{\partial L}{\partial z} \times z(1 - z)$

表 2: 常见操作的梯度计算规则

5 梯度下降

5.1 优化问题的数学表述

在机器学习中，训练模型可以形式化为一个优化问题：

机器学习优化问题

给定训练数据集 $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$ ，模型参数 θ ，损失函数 \mathcal{L} ，我们的目标是：

$$\min_{\theta} \mathcal{L}(\theta) = \frac{1}{N} \sum_{i=1}^N \ell(f(x_i; \theta), y_i)$$

其中 $f(x; \theta)$ 是模型预测， ℓ 是单个样本的损失函数。

5.2 梯度下降的基本思想

梯度下降（Gradient Descent）是最基本的优化算法，其核心思想是利用梯度信息来寻找函数的最小值。

梯度下降的直观理解

想象你在山上，想要下到山谷：

- **当前位置**：当前参数值 θ
- **梯度**：最陡的下山方向 $-\nabla \mathcal{L}(\theta)$
- **学习率**：步长大小 α
- **更新**：沿着最陡方向走一小步 $\theta \leftarrow \theta - \alpha \nabla \mathcal{L}(\theta)$

5.3 梯度下降的数学表达

梯度下降算法

对于参数 θ ，梯度下降的更新规则为：

$$\theta_{t+1} = \theta_t - \alpha \nabla \mathcal{L}(\theta_t)$$

其中：


- θ_t ：第 t 次迭代的参数值
- α ：学习率（步长）
- $\nabla \mathcal{L}(\theta_t)$ ：损失函数在 θ_t 处的梯度

5.4 学习率的重要性

学习率是梯度下降中最重要的超参数之一，它控制着参数更新的步长：


学习率太小

- 收敛速度很慢
- 需要很多迭代
- 可能陷入局部最优

 小步移动

学习率太大

- 可能错过最优解
- 在最优解附近震荡
- 甚至发散（不收敛）

 来回震荡

选择合适的学习率

- 通常从 0.01, 0.001 等值开始尝试
- 可以随着训练逐渐减小（学习率衰减）
- 使用自适应方法（如 Adam, RMSprop）
- 通过验证集性能来选择最佳学习率

5.5 梯度下降的变体

根据使用数据量的不同，梯度下降有多种变体：

算法类型	更新规则	特点
批量梯度下降	$\theta \leftarrow \theta - \alpha \nabla \mathcal{L}(\theta)$	使用全部数据，稳定但慢
随机梯度下降	$\theta \leftarrow \theta - \alpha \nabla \ell_i(\theta)$	使用单个样本，快但不稳定
小批量梯度下降	$\theta \leftarrow \theta - \alpha \nabla \mathcal{L}_B(\theta)$	使用小批量，平衡稳定性和速度

表 3: 梯度下降算法变体对比

5.6 梯度下降的收敛性分析

梯度下降的收敛性可以通过数学分析来理解：

收敛性条件

如果损失函数 \mathcal{L} 是凸函数且 Lipschitz 连续，即存在 $L > 0$ 使得：

$$\|\nabla \mathcal{L}(\theta) - \nabla \mathcal{L}(\theta')\| \leq L \|\theta - \theta'\|$$

那么当学习率 $\alpha < \frac{2}{L}$ 时，梯度下降保证收敛到全局最优解。

对于非凸函数（如神经网络），梯度下降只能保证收敛到局部最优解或鞍点。

6 综合实例：训练线性回归模型

6.1 问题设定

让我们通过一个完整的例子来演示计算图、反向传播和梯度下降的协同工作。我们要训练一个简单的线性回归模型：

线性回归模型

模型： $f(x) = wx + b$ 数据点： $(2, 5)$ 损失函数： $L = (\hat{y} - y)^2$ 目标：找到最优的 w 和 b

6.2 计算图表示




图 4: 线性回归模型的计算图

6.3 详细训练过程

第 1 轮迭代详细计算

初始化: $w = 1, b = 0$, 学习率 $\alpha = 0.1$

前向传播:

$$1. \hat{y} = w \times x + b = 1 \times 2 + 0 = 2$$

$$2. L = (\hat{y} - y)^2 = (2 - 5)^2 = 9$$

反向传播:

$$1. \frac{\partial L}{\partial \hat{y}} = 2(\hat{y} - y) = 2(2 - 5) = -6$$

$$2. \frac{\partial \hat{y}}{\partial w} = x = 2, \frac{\partial \hat{y}}{\partial b} = 1$$

$$3. \frac{\partial L}{\partial w} = \frac{\partial L}{\partial \hat{y}} \times \frac{\partial \hat{y}}{\partial w} = -6 \times 2 = -12$$

$$4. \frac{\partial L}{\partial b} = \frac{\partial L}{\partial \hat{y}} \times \frac{\partial \hat{y}}{\partial b} = -6 \times 1 = -6$$

梯度下降更新:

$$1. w_{\text{新}} = w - \alpha \frac{\partial L}{\partial w} = 1 - 0.1 \times (-12) = 2.2$$

$$2. b_{\text{新}} = b - \alpha \frac{\partial L}{\partial b} = 0 - 0.1 \times (-6) = 0.6$$

结果: 新的参数 $w = 2.2, b = 0.6$, 预测值 $\hat{y} = 2.2 \times 2 + 0.6 = 5.0$, 更接近真实值 $y = 5$ 。

6.4 多轮迭代的收敛过程

通过多轮迭代, 模型会逐步收敛到最优解:

迭代轮数	w	b	预测值 \hat{y}	损失 L
0	1.000	0.000	2.000	9.000
1	2.200	0.600	5.000	0.000
2	2.200	0.600	5.000	0.000

表 4: 线性回归训练过程

可以看到，仅经过一轮迭代，模型就找到了完美拟合数据的参数。

7 现代深度学习框架的实现

7.1 自动微分系统

现代深度学习框架（如 PyTorch、TensorFlow、JAX）都内置了自动微分系统，这些系统基于计算图和反向传播原理：

自动微分的关键特性

- **动态计算图**：在运行时构建计算图，便于调试和动态控制流
- **静态计算图**：预先构建完整的计算图，优化执行效率
- **梯度追踪**：自动记录前向传播的操作序列
- **内存优化**：智能管理中间结果的存储和释放

7.2 PyTorch 实现：手动构建计算图

让我们通过 PyTorch 来手动实现计算图、反向传播和梯度下降，深入理解这些概念的实际应用：

手动实现计算图和反向传播

```
1 import torch
2 import torch.nn as nn
3 import matplotlib.pyplot as plt
4
5 class ManualComputationalGraph:
6     """手动实现计算图和反向传播"""
7
8     def __init__(self):
9         # 初始化参数
10         self.w = torch.tensor(1.0, requires_grad=True)
11         self.b = torch.tensor(0.0, requires_grad=True)
12         self.learning_rate = 0.1
13
14     def forward_pass(self, x):
15         """前向传播：计算预测值和损失"""
16         # 线性模型：y_pred = w * x + b
17         y_pred = self.w * x + self.b
18
19         # 均方误差损失：L = (y_pred - y_true)^2
20         loss = (y_pred - y_true) ** 2
21
22         return y_pred, loss
23
24     def backward_pass(self, x, y_true, y_pred):
25         """反向传播：手动计算梯度"""
26         # 清空之前的梯度
27         if self.w.grad is not None:
28             self.w.grad.zero_()
29         if self.b.grad is not None:
30             self.b.grad.zero_()
31
32         # 反向传播计算梯度
33         loss = (y_pred - y_true) ** 2
34         loss.backward()
35
36         return self.w.grad.item(), self.b.grad.item()
37
38     def update_parameters(self):
39         """梯度下降：更新参数"""
40         with torch.no_grad():
41             self.w -= self.learning_rate * self.w.grad
42             self.b -= self.learning_rate * self.b.grad
```

7.3 现代优化器的工作机制与对比

现代深度学习框架提供了多种优化算法，每种算法都有其独特的工作机制。让我们通过流程图和数学表达式来深入理解这些优化器的工作原理。

7.3.1 优化器的基本框架

所有优化器都遵循相似的基本框架，但在梯度处理和参数更新策略上有所不同。

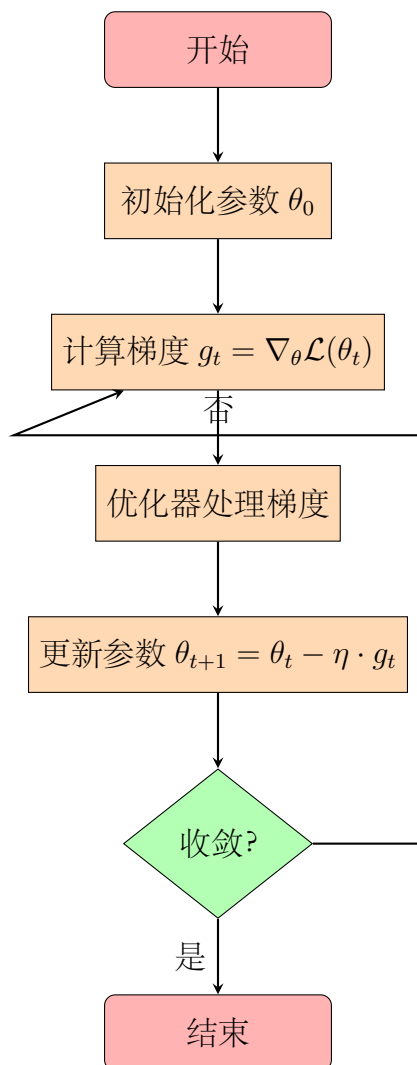


图 5: 优化器通用工作流程

7.3.2 随机梯度下降 (SGD)

SGD 是最基础的优化器，直接使用计算出的梯度进行参数更新。


SGD 数学原理

- 梯度计算: $g_t = \nabla_{\theta} \mathcal{L}(\theta_t)$
- 参数更新: $\theta_{t+1} = \theta_t - \eta \cdot g_t$

其中:

- g_t : 第 t 步的梯度 (gradient)
- θ_t : 第 t 步的参数 (parameters)
- η : 学习率 (learning rate)
- \mathcal{L} : 损失函数 (loss function)

SGD 特点:



- 简单直接，无额外计算
- 可能震荡，收敛不稳定
- 容易陷入局部最优
- 对学习率敏感

图 6: SGD 优化器工作流程

7.3.3 带动量的 SGD (SGD+Momentum)

动量法通过累积之前的梯度信息来加速收敛并减少震荡。

动量法数学原理

- 动量累积: $m_t = \beta \cdot m_{t-1} + (1 - \beta) \cdot g_t$
- 参数更新: $\theta_{t+1} = \theta_t - \eta \cdot m_t$

其中:

- m_t : 第 t 步的动量 (momentum)
- m_{t-1} : 上一步的动量
- β : 动量系数, 通常设为 0.9
- g_t : 当前梯度
- η : 学习率

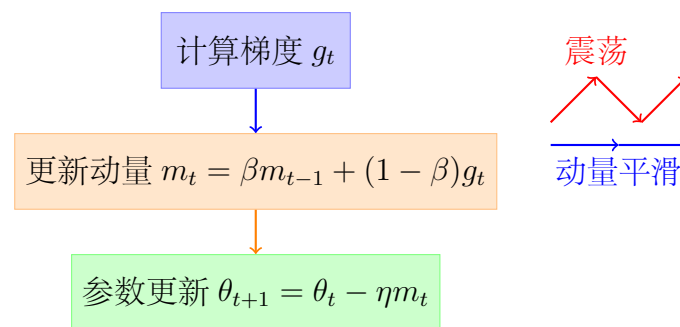


图 7: 动量法工作流程与效果

7.3.4 RMSprop 优化器

RMSprop 通过自适应调整每个参数的学习率来解决学习率选择问题。

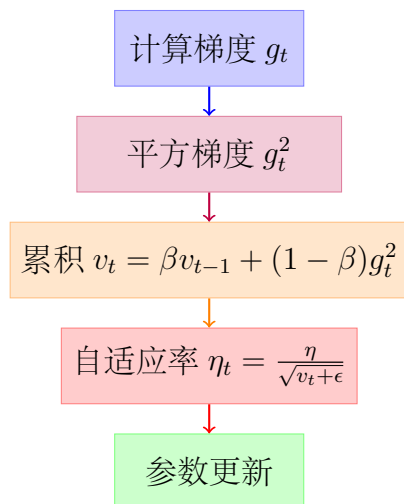
RMSprop 数学原理

- 平方梯度累积: $v_t = \beta \cdot v_{t-1} + (1 - \beta) \cdot g_t^2$
- 自适应学习率: $\eta_t = \frac{\eta}{\sqrt{v_t + \epsilon}}$
- 参数更新: $\theta_{t+1} = \theta_t - \eta_t \cdot g_t$

其中:

- v_t : 第 t 步的平方梯度累积 (second moment)
- v_{t-1} : 上一步的平方梯度累积
- β : 衰减系数, 通常设为 0.999
- g_t^2 : 当前梯度的平方 (element-wise)
- ϵ : 小常数, 防止除零 (通常 10^{-8})
- η_t : 自适应学习率

RMSprop 特点:



- 为每个参数分配不同学习率
- 对频繁更新的参数减小学习率
- 对稀疏更新的参数保持学习率
- 适合处理非平稳目标

图 8: RMSprop 优化器工作流程

7.3.5 Adam 优化器

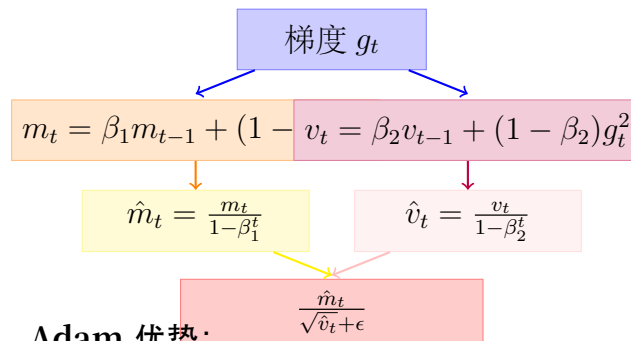
Adam (Adaptive Moment Estimation) 结合了一阶动量和二阶动量, 是目前最流行的优化器之一。

Adam 数学原理

- 一阶动量 (均值): $m_t = \beta_1 \cdot m_{t-1} + (1 - \beta_1) \cdot g_t$
- 二阶动量 (方差): $v_t = \beta_2 \cdot v_{t-1} + (1 - \beta_2) \cdot g_t^2$
- 偏差校正: $\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \hat{v}_t = \frac{v_t}{1 - \beta_2^t}$
- 参数更新: $\theta_{t+1} = \theta_t - \eta \cdot \frac{\hat{m}_t}{\sqrt{\hat{v}_t + \epsilon}}$

其中:

- m_t : 一阶动量 (梯度均值)
- v_t : 二阶动量 (梯度方差)
- β_1 : 一阶衰减系数, 通常设为 0.9
- β_2 : 二阶衰减系数, 通常设为 0.999
- \hat{m}_t, \hat{v}_t : 偏差校正后的动量
- t : 当前时间步 (用于偏差校正)



Adam 优势:

- 结合动量法和自适应学习率的优点
- 偏差校正解决冷启动问题
- 对超参数相对不敏感
- 适合大多数深度学习任务

图 9: Adam 优化器完整工作流程

7.3.6 优化器对比分析

不同优化器在收敛速度、稳定性和适用场景方面各有特点。

优化器	核心思想	主要优势	适用场景
SGD	简单直接	收敛慢	易实现
SGD+Momentum	加速收敛	减少震荡	通用性好
RMSprop	自适应学习率	适合稀疏数据	非平稳目标
Adam	结合动量和自适应	鲁棒性强	最常用

表 5: 主流优化器特性对比

7.3.7 优化器选择指导

选择合适的优化器需要考虑多个因素：

选择优化器的实用建议

1. 对于简单问题：使用 SGD 或 SGD+Momentum
2. 对于深度学习：优先尝试 Adam
3. 对于稀疏数据：考虑 RMSprop 或 Adam
4. 对于非平稳目标：使用 RMSprop 或 Adam
5. 对于资源受限场景：使用 SGD（计算量最小）

重要提醒

优化器的选择并非一成不变，应该：

- 根据具体任务和数据特点进行实验对比
- 考虑计算资源和时间成本
- 注意不同优化器对学习率的敏感性差异
- 可以结合学习率调度策略获得更好效果

7.4 优化器的抽象

现代框架提供了各种优化器来简化梯度下降过程：

使用优化器

```
1 import torch.optim as optim
2
3 # 定义模型和优化器
4 model = torch.nn.Linear(1, 1) # 线性回归模型
5 optimizer = optim.SGD(model.parameters(), lr=0.1)
6
7 # 训练循环
8 for epoch in range(100):
9     # 前向传播
10    y_pred = model(x)
11    loss = (y_pred - y_true) ** 2
12
13    # 反向传播
14    optimizer.zero_grad() # 清空梯度
15    loss.backward()       # 计算梯度
16    optimizer.step()      # 更新参数
```

7.5 梯度消失与梯度爆炸

在深层网络中，反向传播可能面临梯度消失或梯度爆炸问题：

梯度消失 (Vanishing Gradient)

- 原因：连续的小梯度相乘导致最终梯度趋近于零
- 影响：深层网络的前面层无法有效学习
- 解决方案：ReLU 激活函数、残差连接、批量归一化

梯度爆炸 (Exploding Gradient)

- 原因：连续的大梯度相乘导致梯度数值溢出
- 影响：训练不稳定，参数更新过大
- 解决方案：梯度裁剪、权重初始化、学习率调整

7.6 二阶优化方法

除了梯度下降，还有基于二阶导数的优化方法：

方法	原理	特点
牛顿法	使用 Hessian 矩阵	收敛快但计算昂贵
拟牛顿法	近似 Hessian 矩阵	平衡收敛速度和计算成本
共轭梯度法	利用共轭方向	适合大规模问题
自然梯度	考虑参数空间的几何结构	在信息几何框架下优化

表 6: 二阶优化方法对比

7.7 自适应优化算法

现代深度学习广泛使用自适应优化算法：

Adam 优化器

Adam (Adaptive Moment Estimation) 结合了动量法和 RMSProp 的优点：

- **动量**：累积梯度的一阶矩（均值）
- **自适应学习率**：累积梯度的二阶矩（未中心化的方差）
- **偏差校正**：解决初始阶段的偏差问题

更新规则：

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (1)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (2)$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t} \quad (3)$$

$$\hat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad (4)$$

$$\theta_{t+1} = \theta_t - \alpha \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} \quad (5)$$

8 结论与实践指导

8.1 核心概念总结与学习成果

通过本章节的学习，我们系统性地掌握了深度学习中的三个核心数学基础：

计算图：数学表达式的可视化表示

核心理解：

- 将复杂计算分解为基本操作的图结构
- 为自动微分提供数学基础
- 便于理解和调试复杂模型

实践技能：

- 能够手动构建简单模型的计算图
- 理解 PyTorch 中动态计算图的工作原理
- 掌握计算图的拓扑排序和依赖关系分析

反向传播：高效的梯度计算算法

核心理解：

- 基于链式法则从输出向输入传播梯度
- 避免了重复计算，大大提高了效率
- 是现代深度学习框架的核心

实践技能：

- 能够手动推导简单函数的梯度
- 理解反向传播中的梯度累积机制
- 掌握常见操作的梯度计算规则

梯度下降：参数优化的基本方法

核心理解：

- 利用梯度信息寻找函数最小值
- 学习率控制更新步长，影响收敛性
- 有多种变体和改进算法

实践技能：

- 能够实现基本的梯度下降算法
- 理解不同优化器的优缺点和适用场景
- 掌握学习率调优的基本方法

8.2 实践应用指南

基于我们的学习经验，以下是实际应用中的关键指导原则：

模型开发流程

1. **问题分析：**明确任务类型（分类、回归等）和数据特征
2. **架构设计：**根据问题复杂度选择合适的网络结构
3. **计算图构建：**设计前向传播的计算流程
4. **损失函数选择：**根据任务类型选择合适的损失函数
5. **优化器配置：**选择适当的优化算法和超参数
6. **训练监控：**实时监控损失和性能指标
7. **调试优化：**分析梯度流，调整网络结构和超参数

常见陷阱与解决方案

- **梯度消失**：使用 ReLU 激活函数、残差连接、适当的权重初始化
- **梯度爆炸**：实施梯度裁剪、减小学习率、使用批量归一化
- **过拟合**：应用 Dropout、L2 正则化、数据增强、早停法
- **欠拟合**：增加模型复杂度、延长训练时间、调整学习率
- **收敛缓慢**：尝试自适应优化器（Adam、RMSprop）、调整批量大小

8.3 从理论到实践的进阶路径

掌握这些基础概念后，读者可以沿着以下路径继续深入学习：

进阶学习建议

1. **深入数学理论**：学习更优化理论、凸优化、数值分析
2. **复杂架构设计**：研究 CNN、RNN、Transformer 等不同架构的计算图特点
3. **高级优化技术**：探索二阶优化方法、元学习、自适应学习率调度
4. **分布式训练**：理解数据并行、模型并行的梯度聚合机制
5. **实际项目应用**：在计算机视觉、自然语言处理等领域实践这些概念

技术发展历程与前沿趋势

这些概念的发展体现了深度学习领域的演进：

- **1960s-1970s**：理论基础建立，反向传播思想萌芽
- **1980s**：反向传播算法被重新发现和推广
- **1990s**：计算图概念在自动微分中系统化
- **2000s**：深度学习框架开始集成这些技术
- **2010s 至今**：成为所有现代 AI 系统的标准组件
- **当前前沿**：神经架构搜索、自动机器学习、量子机器学习

重要启示

计算图、反向传播和梯度下降不仅是技术工具，更是理解深度学习本质的钥匙。掌握这些基础概念，能够帮助我们：

- **设计更好的模型**：理解如何构建高效的神经网络架构
- **调试训练问题**：快速定位和解决训练过程中的各种问题
- **推动技术创新**：基于这些原理开发新的算法和技术
- **跨领域应用**：将这些概念应用到不同的机器学习任务中

正如我们在 MNIST 实例中看到的，这些看似抽象的数学概念，实际上是解决实际问题的强大工具。

参考文献

- [1] Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323(6088), 533-536.
- [2] LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436-444.
- [3] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- [4] Baydin, A. G., Pearlmutter, B. A., Radul, A. A., & Siskind, J. M. (2018). Automatic differentiation in machine learning: a survey. *Journal of Machine Learning Research*, 18(1), 5595-5637.
- [5] Kingma, D. P., & Ba, J. (2014). Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*.
- [6] Bottou, L., Curtis, F. E., & Nocedal, J. (2018). Optimization methods for large-scale machine learning. *SIAM Review*, 60(2), 223-311.
- [7] Pascanu, R., Mikolov, T., & Bengio, Y. (2013). On the difficulty of training recurrent neural networks. In *International conference on machine learning* (pp. 1310-1318).
- [8] Sutskever, I., Martens, J., Dahl, G., & Hinton, G. (2013). On the importance of initialization and momentum in deep learning. In *International conference on machine learning* (pp. 1139-1147).